

MATEMATIČKI FAKULTET



Vision transformer

Seminarski rad u okviru kursa Računarska inteligencija

Jovan Vlatković 176/2021

Septembar 2026.

Sadržaj

1	Uvod	2
2	Teorijska pozadina	2
2.1	Podela slike na delove i vektorizacija	3
2.2	Poziciona ugradnja i CLS token	3
2.3	Transformer enkoder	3
2.3.1	Normalizacioni sloj	4
2.3.2	Mehanizam pažnje i MSA sloj	4
2.3.3	Višeslojni perceptron (MLP)	5
2.4	Klasifikaciona glava	6
3	Eksperiment	6
3.1	Skup podataka	6
3.2	Postavka	7
3.3	Rezultati	7
3.4	Diskusija	8
4	Zaključak	9
	Literatura	9

1 Uvod


Vision transformer (ViT) je adaptacija arhitekture transformera, prvobitno dizajnirane za obradu prirodnog jezika, za primenu u obradi i analizi slika. Umesto da sliku posmatra kao matricu piksela, ViT deli sliku na manje delove (eng. patch), pretvara ih u sekvencu tokena i primenjuje mehanizam pažnje da bi razumeo odnose između različitih delova slike.

Kao jedna od najuspešnijih arhitektura dubokog učenja za obradu vizuelnih podataka ističe se konvolutivna neuronska mreža (CNN), pa su prvi pokušaji primene ideja iz arhitekture transformera upravo bili zasnovani na CNN modelima. Jedan pristup je bio nad modelom ResNet, gde je svaki njegov konvolutivni filter zamenjen mehanizmom samopažnje (self-attention) koji se pronalazi u transformerima. ViT arhitektura prilagođava slike za ulaz u transformer enkoder i time koristi samo deo cele arhitekture. ViT se pokazao kao konkurencija za CNN i postiže bolje rezultate na skupovima podataka većih dimenzija.

Cilj ovog rada je teorijski opis ViT arhitekture, kreiranje i evaluacija modela za klasifikaciju slika zasnovanog na ovoj arhitekturi i poređenje rezultata sa CNN modelom treniranim na istom skupu podataka.

2 Teorijska pozadina

Transformer arhitektura ima enkoder-dekoder strukturu (oba su odvojene potpuno povezane neuronske mreže), gde enkoder mapira ulaznu sekvencu reprezentacija simbola $(x_1, \dots, x_n)$ u sekvencu neprekidnih reprezentacija $\mathbf{z} = (z_1, \dots, z_n)$. Dekoder tad za ulaz uzima $\mathbf{z}$ i generiše izlaznu sekvencu $(y_1, \dots, y_m)$ simbola element po element. Na svakom koraku model je auto-regresivan tj. uzima prethodno generisan simbol kao dodatni ulaz za generisanje sledećeg. ViT ima samo enkoder, pa ga u nastavku detaljno obrađujemo.



Slika 1: Arhitektura ViT-a

2.1 Podela slike na delove i vektorizacija

Ulaz u enkoder predstavlja jednodimenziona sekvenca vektorskih reprezentacija tokena, pa je potrebno slike prilagoditi ovoj reprezentaciji. Prvo je potrebno sliku podeliti na N delova, što znači da se slika $x \in \mathbb{R}^{H \times W \times C}$ preoblikuje u sekvencu vektorizovanih 2D delova $x_p \in \mathbb{R}^{N \times (P^2 \cdot C)}$, gde je (H, W) rezolucija slike, C broj kanala, (P, P) rezolucija svakog dela i $N = H \cdot W / P^2$ broj delova. Transformer kroz sve svoje slojeve koristi vektor konstantne veličine D pa sve delove vektorizujemo i mapiramo u D dimenzija koristeći naučivu linearnu projekciju $z_0^i = x_p^i E$, $\forall i \in \{1, \dots, N\}$ gde je $E \in \mathbb{R}^{(P^2 \cdot C) \times D}$ matrica čiji se parametri uče.

2.2 Poziciona ugradnja i CLS token


Poziciona ugradnja se dodaje vektorizovanim delovima slike zbog očuvanja pozicionih informacija tj. prostorne strukture. Za ovu ugradnju se koriste naučivi pozicioni vektori, predstavljeni kao kolone matrice $E_{pos} \in \mathbb{R}^{(N+1) \times D}$, sa kojima se predstavljaju lokalni i globalni odnosi između delova slike. Bez pozicione ugradnje, model ne može da napravi razliku između npr. gornjeg levog i donjeg desnog dela slike, a ovo je izuzetno štetno jer susedni delovi dele vizuelni kontekst.

Naučivi klasifikacioni (CLS) token se dodaje u sekvencu vektorizovanih delova slike ($z_0^0 = x_{CLS}$) čije stanje na izlazu iz transformer enkodera (z_L^0) predstavlja reprezentaciju slike $\mathbf{y}$. Zahvaljujući mehanizmu samopažnje CLS token uzima u obzir informacije sadržane u ostalim tokenima i time formira celokupnu reprezentaciju slike. Koristi se za klasifikaciju tj. kao ulaz u klasifikacioni sloj.

2.3 Transformer enkoder

Sada je ulaz u transformer enkoder predstavljen sekvencom tokena:

$$\mathbf{z}_0 = [x_{CLS}; x_p^1 E; \dots; x_p^N E] + E_{pos}$$



Slika 2: Arhitektura Transformer enkodera za ViT

Enkoder je sačinjen kao stek od L identičnih slojeva. Svaki sloj ima dva podsloja. Prvi je sloj višeglave samopažnje (eng. multi-head self-attention (MSA)), a drugi višeslojni perceptron (eng. multi-layer perceptron (MLP)). Pred svaki podsloj postoji normalizacioni sloj (layer normalization (LN)). Nad izlazom iz svakog podsloja primenjujemo rezidualnu vezu u vidu sabiranja sa ulazom tog podsloja.

$$\mathbf{z}'_l = MSA(LN(\mathbf{z}_{l-1})) + \mathbf{z}_{l-1}, \quad l = 1 \dots L$$

$$\mathbf{z}_l = MLP(LN(\mathbf{z}'_l)) + \mathbf{z}'_l, \quad l = 1 \dots L$$

2.3.1 Normalizacioni sloj

Svaki token u ViT se normalizuje pojedinačno i nezavisno od drugih tokena. Neka jedan token ima reprezentaciju $\mathbf{z}_l^i = (a_{l,1}^i, \dots, a_{l,D}^i)$ tj. token ima D komponenti. Tada računamo statistike svakog tokena tj. srednju vrednost μ_l^i i standardnu devijaciju σ_l^i kao:

$$\mu_l^i = \frac{1}{D} \sum_{j=1}^D a_{l,j}^i \quad \sigma_l^i = \sqrt{\frac{1}{D} \sum_{j=1}^D (a_{l,j}^i - \mu_l^i)^2}$$

Normalizacija sloja je tada predstavljena kao funkcionalno mapiranje $LN : \mathbb{R}^D \rightarrow \mathbb{R}^D$ sa dva adaptivna (naučiva) vektora, skaliranja α_l^i i pomeranja β_l^i . Sada je:

$$LN(\mathbf{z}_l^i; \alpha_l^i, \beta_l^i) = \frac{(\mathbf{z}_l^i - \mu_l^i)}{\sigma_l^i} \odot \alpha_l^i + \beta_l^i$$

čime se dobijaju stabilne reprezentacije tokena.

2.3.2 Mehanizam pažnje i MSA sloj

Intuitivno mehanizam pažnje omogućava svakom tokenu u sekvenci da odredi koji od ostalih tokena sadrže relevantne informacije za razumevanje konteksta i formiranje njegove nove reprezentacije.


Funkcija pažnje (attention) se može opisati kao mapiranje upita i skupa ključ-vrednost parova u izlaz, gde su upit, ključ, vrednost i izlaz vektori. Izlaz se računa kao težišna suma vrednosti, gde se težine dodeljene svakoj vrednosti računaju koristeći funkciju kompatibilnosti upita sa odgovarajućim ključem.

Kao osnovnu verziju koristimo skaliranu pažnju zasnovanu na skalarnom proizvodu. Ulaz se sastoji od upita i ključeva dimenzije d_k i vrednosti dimenzije d_v . Računamo skalarni proizvod upita sa svim ključevima, delimo svaki sa $\sqrt{d_k}$ i primenjujemo *softmax* funkciju za dobijanje težina za vrednosti. U praksi računamo funkciju pažnje na celom skupu upita istovremeno, raspoređenih u matricu Q . Ključevi i vrednosti su takođe raspoređeni u matrice K i V redom. Računamo matricu izlaza kao:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Aktivaciona funkcija *softmax* transformiše vektor numeričkih vrednosti u raspodelu verovatnoća. Za dati vektor $\mathbf{v} = (v_1, \dots, v_n)$ data je kao:

$$\sigma(v_i) = \frac{e^{v_i}}{\sum_{j=1}^n e^{v_j}}$$



Slika 3: Struktura mehanizma pažnje i MSA sloja

Umesto upotrebe jedne funkcije pažnje sa D dimenzionim ključevima, vrednostima i upitima, linearno projektujemo upite, ključeve i vrednosti h puta sa različitim, naučenim linearnim projekcijama u d_k , d_k i d_v dimenzije redom. Nad svakom od projektovanih verzija ovih vektora koristimo funkciju pažnje paralelno čime dobijamo izlazne vrednosti dimenzije d_v . One se spajaju i ponovo linearno projektuju što rezultuje konačni izlaz.

Svako linearno projektovanje nad upitima, ključevima i vrednostima predstavlja jednu od h glava multi-head attention sloja. Glava je data sa:

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V)$$

gde su projekcije parametarske matrice $W_i^Q \in \mathbb{R}^{D \times d_k}$, $W_i^K \in \mathbb{R}^{D \times d_k}$, $W_i^V \in \mathbb{R}^{D \times d_v}$. Multi-head attention sloj je tada predstavljen kao:

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O$$

gde je linearna projekcija parametarska matrica $W^O \in \mathbb{R}^{hd_v \times D}$.

U ViT se koristi mehanizam samopažnje u kome se upiti, ključevi i vrednosti dobijaju iz iste sekvence tokena. Zbog toga su početne vrednosti K, Q i V za multi-head self-attention (MSA) sloj zapravo izlaz iz prethodnog sloja enkodera.

2.3.3 Višeslojni perceptron (MLP)

Višeslojni perceptron (MLP) je potpuno povezana neuronska mreža koja je sačinjena od ulaznog, izlaznog i skrivenih slojeva. Na skrivenom sloju se primenjuje nelinearna aktivaciona funkcija.

MLP transformiše svaki token u prostor veće dimenzije zarad veće ekspresivnosti i vraća ih u početnu dimenziju. Za ViT osnovna arhitektura MLP-a je sačinjena od dva linearna sloja sa GELU aktivacionom funkcijom. Neka je ulaz u MLP vektor $\mathbf{x}$, tada je:

$$MLP(\mathbf{x}) = W_2 GELU(W_1 \mathbf{x} + b_1) + b_2$$

gde su W_1 i W_2 matrice težina, b_1 , b_2 vektori pomeranja (*bias*).

Aktivaciona funkcija GELU (Gaussian Error Linear Unit) je bazirana na kumulativnoj funkciji normalne raspodele tj. $GELU(x) = x \cdot \Phi(x)$. Kako se ona računarski teško dobija koristi se aproksimacija:

$$GELU(x) \approx 0.5 \cdot x \cdot \left(1 + \tanh \left(\sqrt{\frac{2}{\pi}} \cdot (x + 0.044715 \cdot x^3) \right) \right)$$

2.4 Klasifikaciona glava

Kao izlaz iz enkoder bloka dobijamo sekvencu tokena gde je prvi upravo CLS token koji sadrži reprezentaciju slike nad kojom se vrši normalizacija:

$$\mathbf{y} = LN(\mathbf{z}_L^0)$$

Ova reprezentacija se koristi kao ulaz u klasifikacionu glavu, koja predstavlja neuronsku mrežu koja predstavlja linearni sloj i kao završna komponenta ViT-a donosi odluku o pripadnosti slike određenoj klasi.

$$\text{logits} = W_{cls} \mathbf{y} + b_{cls}$$


Broj logita zavisi od broja klasa i nad njima se primenjuje *softmax* funkcija čime se dobijaju tražene verovatnoće pripadnosti klasama.

3 Eksperiment

Za kreiranje modela ViT arhitekture korišćeni su programski jezik Python i biblioteka PyTorch. Cilj eksperimenta je evaluacija rezultata klasifikacije nad skupom podataka WikiArt Art Movements/Styles i poređenje sa rezultatima modela baziranog na CNN arhitekturi.

3.1 Skup podataka

Korišten je skup podataka [WikiArt Art Movements/Styles](#) koji sadrži 42500 slika (umetničkih dela) raspoređenih u 13 klasa koje predstavljaju umetnički pravac tj. stil kojem pripadaju. Svaka slika je formata '.jpg' različitih rezolucija, pa je potrebno ujednačiti veličine tokom preprocesiranja podataka. ViT se dobro pokazuje u radu nad slikama rezolucije 224×224 i zbog toga se ta veličina koristi u ovom eksperimentu. Za evaluaciju modela za problem klasifikacije potrebno je podeliti skup podataka na trening i test skup, za veličinu test skupa se uzima 20% celokupnog skupa, dok je ostatak trening skup.



Slika 4: Broj slika u trening i test skupu po klasama

3.2 Postavka


Treniramo dva modela, prvi baziran na ViT, a drugi CNN arhitekturi. Za oba modela se koriste Adam (Adaptive Moment Estimation) optimizator i Cross-entropy loss funkciju gubitka. Treniramo ih kroz 20 epoha gde se nakon svake primenjuje augmentacija podataka zarad dobijanja novih varijanti slika za treniranje čime se smanjuje mogućnost preprilagođavanja. Za treniranje ne koristimo ceo skup podataka da bi se samo treniranje izvršilo u razumnom vremenu. Uzimamo po 1000 slika za svaku klasu i time dobijamo smanjen skup podataka sa jednako zastupljenim klasama.

Za ViT koristimo arhitekturu sa $L = 4$ enkoder bloka u kojima se primenjuje opisan mehanizam samopažnje u MSA sloju sa $h = 4$ glave. Dimenzija svakog tokena je $D = 128$, dok je broj tokena tj. delova slike $N = 196$ jer je $P = 16$ i sa CLS tokenom 197.

Za CNN arhitekturu koristimo pet uzastopnih konvolutivnih blokova, gde svaki blok sadrži konvolutivni sloj sa jezgrom dimenzije 3×3 , normalizaciju (batch normalization), ReLU aktivacionu funkciju i sloj Max pooling dimenzije 2×2 .

3.3 Rezultati

Tokom treniranja kroz 20 epoha ViT model dostiže tačnost od 0.5268, dok na validacionom skupu ostvaruje tačnost od 0.4491. CNN model dostiže tačnost od 0.6053, a na validacionom skupu 0.5536. Ovi rezultati su prikazani na slici 5.




Slika 5: Tačnost (levo) i gubitak (desno) kroz epohe


Oba modela se testiraju na skupu koji sadrži 200 slika po klasi. U tabeli 1 su prikazane neke relevantne metrike klasifikacije nad test skupom.

Tabela 1: Poređenje performansi ViT i CNN modela

Model	Accuracy	Macro Precision	Macro Recall	Macro F1	Weighted F1
ViT	0.355	0.401	0.355	0.326	0.326
CNN	0.445	0.494	0.445	0.441	0.441



Slika 6: Tačnost predikcije modela po klasama



Slika 7: Matrice konfuzije modela ViT (levo) i CNN (desno)

3.4 Diskusija

Iz rezultata se primećuje da CNN blago nadmašuje ViT u svim procenama kvaliteta modela. Prvenstveni razlog za to jeste ugrađena induktivna pristrasnost kod CNN modela čime bolje razume slike, kod ViT ova pristrasnost se uči kroz treniranje preko mehanizma samopažnje. U prethodnim eksperimentima pokazano je da ViT daje bolje performanse od CNN modela nad znatno većim skupovima podataka, što u ovom eksperimentu nije bio slučaj.

Oba modela daju naznake preprilagođavanja podacima. Ova osobina se vidi iz jaza između tačnosti tokom treniranja i validiranja kroz epohe. ViT se više preprilagodio od CNN modela. Preprilagođavanje može da se smanji uvođenjem jače augmentacije podataka između epoha, trenutno augmentacija radi samo horizontalnu rotaciju. Augmentacija ne sme biti takva da se gube bitne karakteristike podataka.

4 Zaključak

Primarni fokus rada je bio na teorijskoj pozadini arhitekture Vision transformera i implementaciji same arhitekture od nule. Koristeći tu implementaciju treniran je model za klasifikaciju umetničkih dela po pravcima te su prikazani rezultati ovog modela. Sama ViT arhitektura najbolje radi kada sadrži veliki broj težina, kao i veliki skup podataka. Uglavnom se koriste već istrenirani modeli ViT, pa se prilagođavaju rešavanju problema nad manjim skupom podataka, jer kao što je pokazano, treniranje nad manjim skupom ne daje zadovoljavajuće rezultate za realnu primenu.

Literatura

- [1] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention Is All You Need,” *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [2] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, “An Image Is Worth 16×16 Words: Transformers for Image Recognition at Scale,” *International Conference on Learning Representations*, 2021.
- [3] J. L. Ba, J. R. Kiros, and G. E. Hinton, “Layer Normalization,” *arXiv preprint arXiv:1607.06450*, 2016.